

您的稿件编号：（新投稿无编号时暂不作填写）

本稿件需要修改时请联系：

作者：魏传如

手机号：18953350005

邮箱：weichuanru@mail.nankai.edu.cn

请务必确认好作者、单位、基金等相关信息，投稿成功后不得随意修改

http://www.joca.cn

doi:10.11772/j.issn.1001-9081.2025121587

# 基于异构图双通道表征及难负采样策略的药物-靶标相互作用预测方法

魏传如, 刘炯鑫, 乐佳檬, 刘明铭\*, 罗永楠, 秦红, 于广博

(南开大学 软件学院, 天津 300350)

(\*通信作者电子邮箱 liumingming@nankai.edu.cn)

**摘要:** 针对药物-靶标相互作用 (DTI) 预测任务中制约现有模型性能的数据异构多源、标签稀疏、图拓扑不完整与类别不平衡等问题, 提出一种基于异构图双通道表征及难负采样策略进行 DTI 预测的新方法 HDH-DTI (Drug-Target Interaction prediction via Heterogeneous-graph Dual-channel representation and Hard negative sampling)。首先, 构建相似度增强异构图 (SE-HIG), 在药物-药物与靶标-靶标通道上用特征相似度增强边权以修补拓扑缺口; 其次, 提出双通道编码器 (DC-Encoder), 通过多关系上采用关系感知的图采样与聚合 (GraphSAGE) 进行邻域聚合, 并使用偏随机游走和跳字模型学习跨模态语义邻域, 使二者在表征空间中融合以同时捕获高阶结构与语义信息; 最后, 设计自适应配额分配的簇感知难负例采样策略 (TQ-CAHNS), 在“药物簇 $\times$ 靶标簇”分块内自适应分配采样配额并进行难例加权抽样, 兼顾跨簇均衡与难负样例覆盖, 从而稳定训练并提升泛化。HDH-DTI 在 Luo 与 Zheng 两个公开数据集上进行评估, 实验结果表明, 相较于最优基线 AMGDTI (Adaptive Meta-Graph-based Drug-Target Interaction prediction) 方法, HDH-DTI 的曲线下面积 (AUC) 和精确率-召回率曲线下面积 (AUPR) 指标在 Luo 数据集上分别提升了 0.13 和 0.58 个百分点, 在 Zheng 数据集上分别提升了 0.60 和 1.08 个百分点。可见, HDH-DTI 显著提升了复杂数据场景下 DTI 预测的准确性, 为药物发现与再利用等实际应用提供了有效的技术方案。

**关键词:** 药物-靶标相互作用预测; 异构图; 图采样与聚合; 跳字模型; 难负采样

**中图分类号:** TP183

**文献标志码:** A

## Drug-target interaction prediction via heterogeneous-graph dual-channel representation and hard negative sampling

WEI Chuanru, LIU Jiongxin, Le Jiameng, LIU Mingming\*, LUO Yongnan, Qin Hong, YU Guangbo

(College of Software, Nankai University, Tianjin 300350, China)

**Abstract:** To address issues of heterogeneous multi-source data, label sparsity, incomplete graph topology and class imbalance that constrained the performance of existing models in Drug-Target Interaction (DTI) prediction, a novel method for DTI prediction based on heterogeneous-graph dual-channel representation and hard negative sampling, named HDH-DTI (Drug-Target Interaction prediction via Heterogeneous-graph Dual-channel representation and Hard negative sampling), was proposed. First, a Similarity-Enhanced Heterogeneous Interaction Graph (SE-HIG) was constructed, where feature similarity was utilized to augment edge weights in both drug-drug and target-target channels to repair topological gaps. Second, a Dual-Channel Encoder (DC-Encoder) was proposed, which employed relation-aware Graph Sample and aggregate (GraphSAGE) for neighborhood aggregation over multi-relational data and learned cross-modal semantic neighborhoods via biased random walks and the skip-gram model, fusing both in the representation space to capture high-order structural and semantic information. Finally, Tempered-Quota Cluster-Aware Hard Negative Sampling (TQ-CAHNS) was designed. Within each "drug cluster $\times$ target cluster" block, sampling quotas were allocated adaptively, and hard negative instances were weighted and sampled. This approach balanced inter-cluster distribution and ensured coverage of challenging negatives, thereby stabilizing training and improving generalization. HDH-DTI was evaluated on two public datasets, the Luo and Zheng datasets. The experimental results showed that, compared with the best baseline AMGDTI (Adaptive

收稿日期: 2026-01-06; 修回日期: 2026-03-24; 录用日期: yyyy-mm-dd。

基金项目: 天津市自然科学基金资助项目(22JCYBJC01020)

**作者简介:** 魏传如(2002—), 男, 山东淄博人, 硕士研究生, 主要研究方向: 机器学习、生物链接预测; 刘炯鑫(2002—), 男, 广东深圳人, 硕士研究生, 主要研究方向: 机器学习、生物链接预测; 乐佳檬(2001—), 内蒙古乌兰察布人, 硕士研究生, 主要研究方向: 机器学习、生物链接预测; 刘明铭(1979—), 女, 山东东阿人, 副教授, 博士, 主要研究方向: 数据挖掘, 机器学习; 罗永楠(2003—), 福建福州人, 硕士研究生, 主要研究方向: 机器学习、生物链接预测; 秦红(2002—), 云南曲靖人, 硕士研究生, 主要研究方向: 机器学习, 生物链接预测; 于广博(2003—), 山东聊城人, 硕士研究生, 主要研究方向: 机器学习、生物链接预测。

Meta-Graph-based Drug-Target Interaction prediction), HDH-DTI improved Area Under the Curve (AUC) by 0.13 and 0.60 percentage points and Area Under the Precision-Recall curve (AUPR) by 0.58 and 1.08 percentage points on the Luo and Zheng datasets, respectively. Therefore, HDH-DTI significantly enhanced the accuracy of DTI prediction in complex data scenarios, providing an effective technical solution for practical applications such as drug discovery and repurposing.

**Keywords:** Drug-Target Interaction (DTI) prediction; heterogeneous graph; Graph SAmple and aggreGatE (GraphSAGE); skip-gram; hard negative sampling

## 0 引言

药物-靶标相互作用(Drug-Target Interactions, DTI)的准确识别对于药物研发至关重要,但传统实验方法成本高、周期长,难以满足规模化筛选需求<sup>[1]</sup>。为提升效率,早期研究广泛采用相似性与矩阵分解等传统计算方法:一类工作将生物学先验融入模型,例如 Yamanishi 等将化学与基因组空间融合来推进 DTI 预测<sup>[2]</sup>,拉普拉斯正则化最小二乘(Laplacian Regularized Least Squares, LapRLS)利用少量标注与大量未标注数据提升泛化<sup>[3]</sup>;另一类工作以矩阵/因子分解为核心,如 NRLMF(Neighborhood Regularized Logistic Matrix Factorization)通过邻域正则化的逻辑矩阵分解在稀疏场景取得稳健表现<sup>[4]</sup>。在此基础上,网络表示学习方法进一步将多源异构数据(如靶标-靶标、药物-副作用等)整合到统一图结构中,兼顾多通道信息与可解释性:代表性工作 DTINet(a Network integration approach for Drug-Target Interaction prediction)先进行网络扩散与低维表征,再以归纳式矩阵补全推断潜在 DTI<sup>[5]</sup>; NeoDTI(NEural integration of neighbOr information for DTI prediction)则将“邻域信息的神经整合”端到端化,直接在异构图上学习拓扑一致的节点表征并给出 DTI 评分<sup>[6]</sup>。

随着深度学习等技术的发展,基于序列或多模态的 DTI/药物-靶标亲和力(Drug-Target Affinity, DTA)预测方法迅速涌现: DeepDTA (Deep Drug-Target binding Affinity prediction)用卷积网络从药物序列与靶标序列中学习亲和力的判别性表征<sup>[7]</sup>; Tsubaki 等将图神经网络(Graph Neural Networks, GNN)用于分子图、卷积网络用于靶标序列,并引入注意力机制以度量序列子片段的重要性,显著提升跨模态对齐能力<sup>[8]</sup>。与此同时,预训练表征正成为高性能 DTI 系统的重要基石:如 ChemBERTa 通过大规模化学语料学习分子语言表征,能为下游预测提供鲁棒语义先验<sup>[9]</sup>; ESM-2(Evolutionary Scale Modeling-2)等蛋白质语言模型在大规模序列上预训练,有助于在缺乏结构注释时仍获得强表征<sup>[10]</sup>。在图表示学习理论层面, Node2Vec(Node to Vector)借助随机游走与跳字模型(skip-gram)目标捕获“拓扑-上下文”一致性<sup>[11]</sup>,图采样与聚合(Graph SAmple and aggreGatE, GraphSAGE)则通过可归纳的邻域聚合在大规模异构图上实现高效训练与推理<sup>[12]</sup>。

尽管已有进展,但真实的 DTI 预测仍面临三类核心挑战:

1)图构建侧:异构多源数据与拓扑不完备带来噪声边与信息缺口;相似度与已知 DTI 如何在不泄露信息的前提下协同,直接影响下游表征质量<sup>[1,6]</sup>。

2)表示学习侧:既要捕获高阶拓扑与跨模态上下文,又要避免“邻域噪声稀释”“过平滑”等问题;如何将随机游走上下文与多关系聚合统一到同一表征空间仍是难点<sup>[8,11,12]</sup>。

3)训练分布侧:数据中类不平衡问题与“难负样本”普遍存在,随机负采样易造成判别边界松弛;不加约束的难例挖掘则可能引入偏置与不稳定性<sup>[7-8]</sup>。

在此背景下,本文提出了一种基于异构图双通道表征及难负采样策略的药物-靶标相互作用预测方法 HDH-DTI(Drug-Target Interaction prediction via Heterogeneous-graph Dual-channel representation and Hard negative sampling),围绕“图构建—表征学习—负采样”形成协同闭环(如图 1 所示),主要工作如下:

1)构建相似度增强异构图(Similarity-Enhanced Heterogeneous Interaction Graph, SE-HIG),在药物-药物/靶标-靶标通道中引入特征相似度增强边权,并在构建异构图时严格仅使用训练折 DTI 边,既修补拓扑缺口又避免信息泄露<sup>[1,2,6]</sup>;

2)提出双通道编码器(Dual-Channel Encoder, DC-Encoder),分别通过 GraphSAGE 在多关系上进行关系感知聚合,通过偏随机游走与 skip-gram 学习跨模态语义邻域,并在统一表征空间中进行融合,从而同时捕获高阶结构与语义信息<sup>[8,11,12]</sup>;

3)设计自适应配额分配的簇感知难例负采样策略(Tempered-Quota Cluster-Aware Hard Negative Sampling, TQ-CAHNS),在药物簇与靶标簇构成的分块结构下,通过簇级配额调节防止大簇垄断,并在块内依据样本难度进行加权抽样,从而在样本层面兼顾跨簇均衡与难负样例覆盖;同时在训练阶段引入焦点损失函数(Focal Loss),进一步提升本文方法对难例的敏感性与对类别不平衡问题的鲁棒性<sup>[13]</sup>。

## 1 HDH-DTI 方法

HDH-DTI 由三个核心模块与一个预测模块组成:相似度增强异构图(SE-HIG)、双通道编码器(DC-Encoder)、自适应配额分配的簇感知难例负采样(TQ-CAHNS)以及融合预测模块(如图 1 所示)。对于计算出的药物 SMILES(Simplified Molecular Input Line Entry System)字符串、药物二维结构数据与靶标氨基酸序列特征,SE-HIG 首先在同类型通道上计算药物-药物与靶标-靶标的特征相似度,并与训练折中的药物-靶标相互作用边融合,构建相似度增强的异构交互图,得到信噪比更高、拓扑更完整的图结构。随后将 SE-HIG 输出的图与药物、靶标的序列、结构特征一起送入 DC-Encoder:一方面通过偏随机游走与 skip-gram 学习“拓扑-上下文一致”

的图语言表征<sup>[11]</sup>;另一方面在药物-药物相互作用(Drug-Drug Interactions, DDI)/蛋白质-蛋白质相互作用(Protein-Protein Interactions, PPI)/DTI 三类关系上采用 GraphSAGE<sup>[12]</sup>进行关系感知的邻域聚合,两路在表征空间拼接融合,形成同时捕获语义上下文与高阶结构的药物和靶标图嵌入,药物和靶标的序列、结构特征和图嵌入拼接形成药物和靶标的完整特征。接着,在 TQ-CAHNS 模块中,对药物与靶标的完整特征分

别聚类<sup>[14-15]</sup>以构造“药物簇×靶标簇”的块结构,采用温和化配额指数 $\alpha$ 为各块分配采样份额以抑制大簇垄断,并用温度 $T$ 对块内难度分数进行 softmax 加权抽样<sup>[16]</sup>,得到兼顾跨簇覆盖与难负样例强调的平衡样本对。最后,在预测模块中,将药物与靶标的完整特征输入轻量级融合模型 Transformer 中<sup>[17-18]</sup>,然后在多层感知机(MultiLayer Perceptron, MLP)中输出相互作用概率。




图1 HDH-DTI 的架构

Fig. 1 The architecture of HDH-DTI

## 1.1 输入

为了适应 HDH-DTI 的输入,本文为药物分子构建了一个信息全面的特征表示。具体而言,本文不仅利用其 SMILES 序列,更充分挖掘了其二维分子图结构所蕴含的丰富信息。在二维结构特征提取上,本文没有使用感受野有限、依赖消息传递的传统图神经网络(GNN),而是采用了图 Transformer<sup>[19-20]</sup>。它的核心优势在于能够通过全局自注意力机制,一次性感知整个分子图中所有原子的关系,从而有效捕捉那些不直接相连但共同决定药物活性的关键原子对,这是传统 GNN 难以实现的。本文将分子图的邻接关系、键类型等作为结构先验注入注意力计算,引导模型进行更符合化学逻辑的学习。与此同时,本文使用 ChemBERTa 预训练模型<sup>[9]</sup>从 SMILES 序列中提取互补的序列模式特征。最终,药物的二维结构特征与一维序列特征被拼接为一个统一的、信息增强的药物表示。

在靶标侧,对于靶标氨基酸序列,本文利用 ESM-2 这一先进的蛋白质语言模型<sup>[10]</sup>,直接从靶标氨基酸序列中提取高维特征,这些特征隐式地编码了靶标的结构与功能信息,是本文方法的靶标输入。

## 1.2 相似度增强异构图

SE-HIG 模块的设计目的是在不泄露测试信息的前提下,提升药物-靶标异构网络的连通性与信噪比。其核心思路是:在同类型通道(药物-药物、靶标-靶标)中以特征相似度增强边权,并仅引入训练折内的 DTI 边,形成面向下游表征学习的相似度增强异构交互图(如图 2 所示)。

在 SE-HIG 中,对于药物侧和靶标侧该方法均使用由上一步得到的药物和靶标的特征向量作为计算特征相似度的数据,对于给定药物特征矩阵  $\mathbf{X}_d \in \mathbf{R}^{N_d \times D_d}$  与靶标特征矩阵  $\mathbf{X}_p \in \mathbf{R}^{N_p \times D_p}$ ,先对它们的行向量进行 L2 范数归一化,得到行归一化矩阵  $\mathbf{X}_d^{\text{norm}}, \mathbf{X}_p^{\text{norm}}$ ,然后再使用式(1)计算同类实体的余弦相似度矩阵以捕获潜在的结构或语义近邻<sup>[5]</sup>:

$$\begin{cases} \mathbf{S}_d = \mathbf{X}_d^{\text{norm}} (\mathbf{X}_d^{\text{norm}})^T \\ \mathbf{S}_p = \mathbf{X}_p^{\text{norm}} (\mathbf{X}_p^{\text{norm}})^T \end{cases} \quad (1)$$

其中  $N_d$  和  $N_p$  表示药物和靶标的数量,  $D_d$  和  $D_p$  表示单个药物和靶标的特征维度。

然后该方法针对  $\mathbf{S}_d, \mathbf{S}_p$  采用了分位阈值 Top-1% 的方式来选择高相似度边的候选集合  $E_d^{\text{sim}}, E_p^{\text{sim}}$ ,以控制图稀疏度并抑制噪声。

之后该方法将药物-药物相互作用矩阵和靶标-靶标相互作用矩阵的原始结构边(值记为 1)集合  $E_d^{\text{orig}}, E_p^{\text{orig}}$  与得到的高

相似度边集合  $E_d^{\text{sim}}, E_p^{\text{sim}}$  按照保留最大权重的规则进行融合，最后得到带权 DDI/PPI 的邻接矩阵：

$$\begin{cases} A_{ij}^d = \begin{cases} \max(1, S_d(i, j)), & (i, j) \in E_d^{\text{orig}} \text{ or } (i, j) \in E_d^{\text{sim}} \\ 0, & \text{otherwise} \end{cases} \\ A_{ij}^p = \begin{cases} \max(1, S_p(i, j)), & (i, j) \in E_p^{\text{orig}} \text{ or } (i, j) \in E_p^{\text{sim}} \\ 0, & \text{otherwise} \end{cases} \end{cases} \quad (2)$$

得到  $A^d, A^p$  后，将它们与训练子集的 DTI 边(权重设置为 1)共同构成三关系异构图  $G$ ：

$$G = (V_d \cup V_p, E_{\text{DDI}}^{\text{weight}} \cup E_{\text{PPI}}^{\text{weight}} \cup E_{\text{DTI}}^{\text{weight}}) \quad (3)$$

其中  $V_d$  和  $V_p$  分别是药物和靶标节点集合， $E_{\text{DDI}}^{\text{weight}}, E_{\text{PPI}}^{\text{weight}}$  和  $E_{\text{DTI}}^{\text{weight}}$  分别代表 DDI、PPI 和 DTI 邻接矩阵中的带权边集。最后得到异构图后分别导出稀疏矩阵与 DGL(Deep Graph Library)异构图表示，以供后续 GraphSAGE 分关系聚合与偏随机游走和 skip-gram 使用。




图 2 SE-HIG 模块的框架

Fig. 2 The framework of SE-HIG module

### 1.3 双通道编码器

为同时捕获“多关系拓扑”与“语义上下文”，本文在异构图上联合采用关系感知的 GraphSAGE<sup>[12]</sup>与随机游走驱动的 skip-gram<sup>[11]</sup>两条通路进行嵌入学习，并在表征空间内对两条通路得到的特征进行拼接融合(如图 3 所示)。其中 GraphSAGE 在 DGL 异构图(关系集  $F = \{\text{DDI}, \text{PPI}, \text{DTI}\}$ )上进行分关系聚合；skip-gram 则由带跨图偏好的随机游走序列训练，主目标为二元交叉熵损失<sup>[21]</sup>。

**基于异构图的关系感知 GraphSAGE 部分：**设第  $k$  层的输入特征为  $h^{(k-1)}$ ，当前节点为  $u$ ，其邻居节点为  $v$ ，对于每

种关系  $r \in F$ ，将其邻居集合记为  $H_r(u)$ 。首先采用基于均值聚合的图神经网络方法，对每种关系类型分别进行邻域信息聚合，然后在关系维度上进行均值汇聚：

$$\begin{cases} \bar{h}_{r,u}^{(k)} = \frac{1}{|H_r(u)|} \sum_{v \in H_r(u)} W_{r,\text{neigh}}^{(k)} h_v^{(k-1)} \\ \tilde{h}_u^{(k)} = W_{\text{self}}^{(k)} h_u^{(k-1)} + \frac{1}{|F|} \sum_{r \in F} \bar{h}_{r,u}^{(k)} \\ h_u^{(k)} = \sigma(\text{Norm}(\tilde{h}_u^{(k)})) \end{cases} \quad (4)$$

其中  $\sigma$  为非线性激活函数 Sigmoid，Norm 表示层归一化<sup>[22]</sup>， $W$  表示可学习的线性变换矩阵。用  $L$  表示 GraphSAGE 堆叠的层数，在实现中，采用分层邻居采样以控制感受野与显存，最终将  $h^{(L)}$  经全连接映射到目标维度并做 L2 归一化得到 GraphSAGE 的嵌入  $g$ ：

$$g = \frac{\text{FC}(h^{(L)})}{\|\text{FC}(h^{(L)})\|_2} \quad (5)$$

**跨图偏好的随机游走与 skip-gram 部分：**该部分在构建的异构图上进行带偏置的随机游走以获得序列。设当前节点为  $c$ ，上一步为  $l$ ，候选邻居为  $f$ ，边权为  $w_{cf}$ ，图中所有边的集合为  $E$ ，Node2Vec 偏置由超参数  $p, q$  控制，跨图边(药物  $\leftrightarrow$  靶标)再乘以增益  $\beta$ ，则一步转移概率为：

$$\begin{cases} \pi(c \rightarrow f) \propto w_{cf} \cdot \gamma(c, f) \cdot \eta(c, f) \\ \gamma(c, f) = \begin{cases} 1/p, & f = l \\ 1, & (f, l) \in E \\ 1/q, & \text{otherwise} \end{cases} \\ \eta(c, f) = \begin{cases} \beta, & \text{cross-graph edge} \\ 1, & \text{otherwise} \end{cases} \end{cases} \quad (6)$$

对偏随机游走得到的序列，采用窗口大小  $d$  形成(target, context)正样本对；负样本从词表中随机抽取且排除正样本对。设每个样本对的索引为  $(t, o)$ ，其真实标签为  $y_{to}$ ，令点积  $z_{to} = \langle z_t, z_o \rangle$  为 logit，令  $B$  为一个训练批次的样本数，则 skip-gram 的主目标为：

$$J_{\text{sg}} = -\frac{1}{B} \sum_{(t,o)} [y_{to} \ln(\sigma(z_{to})) + (1 - y_{to}) \ln(1 - \sigma(z_{to}))] \quad (7)$$

其中  $z$  的构造见下一段的融合方式。

**融合与对齐部分：**记词嵌入为  $e$ ，已知 GraphSAGE 嵌入为  $g$ ，为进入同一空间，先对它们做线性对齐：

$$\begin{cases} \hat{e} = W_e e + b_e \\ \hat{g} = W_g g + b_g \end{cases} \quad (8)$$

然后采用拼接的方式进行融合： $z = [\hat{e}; \hat{g}]$ 。

在训练前向中, 对一个 (target, context) 样本对, 取  $z_{io} = \langle z_i, z_o \rangle$  作为 BCEWithLogits(Binary Cross-Entropy loss With Logits) 的 logit 计算损失<sup>[23]</sup>; 离线导出时, 则先在全图上通过 GraphSAGE 计算  $g$ , 再与词嵌入权重拼接并按实体类型切分为药物/靶标嵌入用于下游预测。

为进一步提升表征质量, 工程中提供两类可选辅助项, 在实践中它们权重可设为较小或关闭, 在该实验中它们默认开启:

归一化温度缩放交叉熵损失(Normalized Temperature-scaled Cross Entropy Loss, NT-Xent)<sup>[24]</sup>: 该损失旨在拉近锚点与正样本, 同时推远锚点与负样本。设锚点  $a_i$ 、正样本  $s_i$  与负样本集合  $\{n_{i,j}\}$ , 温度  $\tau$ , 则损失可写为:

$$J_{\text{ntxent}} = -\frac{1}{B} \sum_{i=1}^B \ln \frac{\exp(\langle a_i, s_i \rangle / \tau)}{\exp(\langle a_i, s_i \rangle / \tau) + \sum_j \exp(\langle a_i, n_{i,j} \rangle / \tau)} \quad (9)$$




图3 DC-Encoder 模块的框架

Fig. 3 The framework of DC-Encoder module

#### 1.4 自适应配额分配的簇感知难例负采样

为缓解“未标注即负例”的噪声风险与类不平衡对训练的影响, 本文在训练与测试划分上分别采用自适应配额分配的簇感知难例负采样(TQ-CAHNS), 构造与正样本等量(1:1)的负样本集合。其核心思想是: 在“药物簇 $\times$ 靶标簇”的分块内先进行自适应配额分配以保证跨簇覆盖与公平性, 再进行块内难例加权抽样以优先选择更接近决策边界的负例; 若因舍入导致配额不足, 再从剩余候选中补齐<sup>[28]</sup>(如图4所示)。

**聚类与候选集构造:** 给定药物特征  $X_d \in \mathbf{R}^{N_d \times D_d}$ 、靶标特征  $X_p \in \mathbf{R}^{N_p \times D_p}$ 、标签矩阵  $Y \in \{0,1\}^{N_d \times N_p}$ , 分别对药物与靶标聚类, 得到簇分配函数:

邻居对比损失<sup>[25]</sup>: 为保持图结构关系, 该部分在各关系的边集上施加三元组约束, 确保相连节点比随机节点对更相似, 边缘参数为  $m$ :

$$J_{\text{ns}} = \frac{1}{|E|} \sum_{(i,j) \in E} \max(0, \cos(x_i, x_j) - \cos(x_i, x_{j^-}) + m) \quad (10)$$

其中  $j^-$  为随机负邻居,  $x$  为当前用于约束的节点表示(可取  $g$  或融合后的  $z$ )。

最后的综合目标为:

$$J = J_{\text{sg}} + \lambda_{\text{con}} J_{\text{ntxent}} + \lambda_{\text{sage}} J_{\text{ns}} \quad (11)$$

其中  $\lambda_{\text{con}}, \lambda_{\text{sage}}$  为可调权重。实现中采用 Adam 优化<sup>[26]</sup>与余弦退火学习率调度<sup>[27]</sup>, 训练时进行梯度裁剪; 在处理大规模异构图方面, 这种方法可以保证训练的效率。

$$\begin{cases} K_d : \{1,2,\dots,N_d\} \rightarrow \mathbf{Z}_{\geq 0} \\ K_p : \{1,2,\dots,N_p\} \rightarrow \mathbf{Z}_{\geq 0} \end{cases} \quad (12)$$

本文在工程中采用 UMAP(Uniform Manifold Approximation and Projection) 进行降维<sup>[14]</sup>和 HDBSCAN(Hierarchical Density-Based Spatial Clustering of Applications with Noise)进行自动聚类<sup>[15]</sup>。

UMAP 是一种基于非线性流形学习的降维方法, 能够在低维空间中保留高维数据的局部邻域结构。其核心思想在于构建高维数据的近邻图, 并在低维嵌入中侧重于保持局部邻域结构, 同时兼顾一定程度的全局拓扑关系, 从而能更有效地揭示复杂高维空间(如生物表征空间)的内在结构。相较于线性方法, UMAP 在处理非线性、结构复杂的数据时具有显著优势, 常被用于特征可视化与聚类预处理。

在降维的基础上,本文采用HDBSCAN进行自适应聚类。HDBSCAN是一种基于密度的层次聚类算法,它无需预先设定簇的数量,能够识别不同密度的簇结构,并将离散样本标记为噪声,因此对于数据中常见的簇规模不均和噪声干扰等情况具有较好的鲁棒性。

UMAP与HDBSCAN的组合遵循“先在低维嵌入中保持表征空间的邻域结构,再基于密度进行聚类”的流程,是从高维表征中发现稳健簇结构的常用策略,该组合为后续基于簇的采样与分块提供了可靠的结构基础。

基于上述聚类结果,在训练/测试索引子集 $I_d, I_p$ 上,定义簇对 $(\delta, \varepsilon)$ 的候选集:

$$M_{\delta\varepsilon} = \{(i, j) | i \in I_d, j \in I_p, K_d(i) = \delta, K_p(j) = \varepsilon, Y_{ij} = 0\} \quad (13)$$

**簇级自适应配额分配:** 设目标负样本数为 $N_{\text{neg}}$ , 实现中取与正样本数相等的负样本, 记候选量 $Q_{\delta\varepsilon}^{\text{cand}} = |M_{\delta\varepsilon}|$ 。为避免大簇垄断, 按次线性幂次温和化进行配额分配:

$$\begin{cases} O_{\delta\varepsilon} = \frac{(Q_{\delta\varepsilon}^{\text{cand}})^{\alpha}}{\sum_{\delta', \varepsilon'} (Q_{\delta'\varepsilon'}^{\text{cand}})^{\alpha}}; \alpha \in (0, 1) \\ \hat{Q}_{\delta\varepsilon} = \lfloor O_{\delta\varepsilon} \cdot N_{\text{neg}} \rfloor \end{cases} \quad (14)$$

其中 $\alpha$ 越小分配越均衡(默认 $\alpha = 0.65$ )。

若 $(\sum_{\delta, \varepsilon} \hat{Q}_{\delta\varepsilon}) < N_{\text{neg}}$ , 则从剩余候选中随机补齐至 $N_{\text{neg}}$ 。

**块内温度化难例加权抽样:** 为聚焦决策边界, 在每个块内对候选对 $(\phi, \varphi)$ 计算难度分数并按softmax概率无放回采样 $\hat{Q}_{\delta\varepsilon}$ 个。已知药物相似度 $S_d$ 、靶标相似度 $S_p$ , 以及候选对中药物和靶标的正样本集合:

$$\begin{cases} P^+(\phi) = \{\phi' | Y_{\phi'\phi} = 1\} \\ U^+(\phi) = \{\varphi' | Y_{\phi\varphi'} = 1\} \end{cases} \quad (15)$$

则候选对 $(\phi, \varphi)$ 的难度分数定义为:

$$\chi_{\phi\varphi} = \max_{\phi' \in P^+(\phi)} S_d[\phi, \phi'] + \max_{\varphi' \in U^+(\phi)} S_p[\varphi, \varphi'] \quad (16)$$

并以温度 $T$ 进行softmax归一化<sup>[16]</sup>:

$$l_{\phi\varphi} = \frac{\exp(\chi_{\phi\varphi} / T)}{\sum_{(\phi^*, \varphi^*) \in M_{\delta\varepsilon}} \exp(\chi_{\phi^*\varphi^*} / T)} \quad (17)$$

按概率 $l_{\phi\varphi}$ 对 $M_{\delta\varepsilon}$ 无放回采样 $\hat{Q}_{\delta\varepsilon}$ 个样本。若某块候选不足, 则取其全部并在全局剩余候选中补齐。最终对全体负样本去重并截断到 $N_{\text{neg}}$ 。

**与正样本的平衡合成:** 在给定索引子集上, 正样本集合为 $P = \{(i, j) | i \in I_d, j \in I_p, Y_{ij} = 1\}$ , 令 $N_{\text{neg}} = |P|$ , 与得到的负样本集合合并后打散, 形成1:1的平衡训练/测试集。自适应配额提升跨簇覆盖, 难例加权聚焦边界样本, 两者结合能在样本的“多样性-判别性”之间取得平衡。

### 1.5 融合预测

为完成药物-靶标相互作用的最终预测, HDH-DTI采用轻量融合的预测头: 将药物与靶标的基础表征与DC-Encoder输出的图嵌入在特征空间中拼接后, 经线性对齐与层归一化后输入到基于Transformer的跨域交互编码器中, 以显式建模二元对之间的高阶相互作用<sup>[17-18]</sup>; 随后通过残差连接与规范化处理得到融合表示, 最后将其送入多层感知机, 经Sigmoid得到交互概率。




图4 TQ-CAHNS 模块的框架

Fig. 4 The framework of TQ-CAHNS module

**输入与实体级对齐:** 对任意药物-靶标对  $(\theta, \rho)$ , 设基础特征为  $\mathbf{x}_d^{\text{base}}(\theta) \in \mathbf{R}^{D_d}$ 、 $\mathbf{x}_p^{\text{base}}(\rho) \in \mathbf{R}^{D_p}$ , 图嵌入的维度为  $G^*$ , 双通道图嵌入为  $\mathbf{z}_d(\theta), \mathbf{z}_p(\rho) \in \mathbf{R}^{G^*}$ 。先在“实体级”按列拼接:

$$\begin{cases} \boldsymbol{\omega}_d(\theta) = [\mathbf{x}_d^{\text{base}}(\theta); \mathbf{z}_d(\theta)] \in \mathbf{R}^{D_d+G^*} \\ \boldsymbol{\omega}_p(\rho) = [\mathbf{x}_p^{\text{base}}(\rho); \mathbf{z}_p(\rho)] \in \mathbf{R}^{D_p+G^*} \end{cases} \quad (18)$$

再用可学习的对齐映射函数  $\xi_d, \xi_p$  投射到统一隐藏维度  $H^*$ :

$$\begin{cases} \mathbf{x}_d^{\text{proj}}(\theta) = \xi_d(\boldsymbol{\omega}_d(\theta)) \in \mathbf{R}^{H^*} \\ \mathbf{x}_p^{\text{proj}}(\rho) = \xi_p(\boldsymbol{\omega}_p(\rho)) \in \mathbf{R}^{H^*} \end{cases} \quad (19)$$

实现中对齐映射采用由线性层、GELU(Gaussian Error Linear Unit)激活函数和 Dropout 层组成的短 MLP:

$$\xi(\boldsymbol{\omega}) = \text{Dropout}(\text{GELU}(\mathbf{W}_\xi \boldsymbol{\omega} + \mathbf{b}_\xi)) \quad (20)$$

**交互建模与残差融合:** 为显式建模药物-靶标双向交互, 该方法构造了长度为 2 的 token 序列  $[\mathbf{x}_d^{\text{proj}}(\theta), \mathbf{x}_p^{\text{proj}}(\rho)]$  进入单层 Transformer 编码器(记为 Enc)。实现中先将两路向量投影到  $2H^*$ :

$$\begin{cases} \tilde{\mathbf{x}}_d^{\text{proj}}(\theta) = \mathbf{W}_d \mathbf{x}_d^{\text{proj}}(\theta) \in \mathbf{R}^{2H^*} \\ \tilde{\mathbf{x}}_p^{\text{proj}}(\rho) = \mathbf{W}_p \mathbf{x}_p^{\text{proj}}(\rho) \in \mathbf{R}^{2H^*} \end{cases} \quad (21)$$

然后进行堆叠编码, 并与对齐拼接的残差做融合:

$$\begin{cases} [\boldsymbol{\psi}_1, \boldsymbol{\psi}_2] = \text{Enc}([\tilde{\mathbf{x}}_d^{\text{proj}}(\theta), \tilde{\mathbf{x}}_p^{\text{proj}}(\rho)]) \in \mathbf{R}^{2H^*} \\ \boldsymbol{\psi}^{\text{orig}} = [\mathbf{x}_d^{\text{proj}}(\theta); \mathbf{x}_p^{\text{proj}}(\rho)] \in \mathbf{R}^{2H^*} \\ \boldsymbol{\psi}_{\text{pair}} = \text{Norm}\left(\frac{1}{2}(\boldsymbol{\psi}_1 + \boldsymbol{\psi}_2) + \boldsymbol{\psi}^{\text{orig}}\right) \in \mathbf{R}^{2H^*} \end{cases} \quad (22)$$

**多层感知机预测头:** 将融合后的对偶表示  $\boldsymbol{\psi}_{\text{pair}}$  输入 MLP 得到最终 logit, 该 MLP 由三个全连接层组成, 隐藏层维度分别为 1024 和 512, 输出维度为 1, 记  $\zeta_{\theta\rho} \in \mathbf{R}$  则:

$$\zeta_{\theta\rho} = \text{MLP}(\boldsymbol{\psi}_{\text{pair}}) \quad (23)$$

损失函数方面本文采用 Focal Loss 以提升对难例的关注与稳健性<sup>[13]</sup>:

$$\begin{cases} J_{\text{focal}} = \frac{1}{B} \sum_{\theta, \rho} [\alpha_{\text{focal}} (1 - \kappa)^{\gamma_{\text{focal}}} \cdot \text{BCEWithLogits}(\zeta_{\theta\rho}, y_{\theta\rho})] \\ \kappa = \begin{cases} \sigma(\zeta_{\theta\rho}), & y_{\theta\rho} = 1 \\ 1 - \sigma(\zeta_{\theta\rho}), & y_{\theta\rho} = 0 \end{cases} \end{cases} \quad (24)$$

其中  $y_{\theta\rho} \in \{0, 1\}$  为真实标签,  $\sigma$  为非线性激活函数

Sigmoid, 超参数  $\alpha_{\text{focal}}$  用于平衡正负样本的重要性,  $\gamma_{\text{focal}}$  用于降低易分样本的损失贡献, 使模型更关注难分样本。若不启用 Focal Loss, 可直接使用 BCEWithLogits 优化<sup>[23]</sup>。这样, 在 TQ-CAHNS 提供的 1:1 平衡分布下, 预测头能稳定地将上游双通道表征转化为可泛化的交互打分。

## 2 实验与结果分析

### 2.1 数据集

HDH-DTI 在两个公开基准数据集上评测: Luo<sup>[5]</sup>数据集与 Zheng<sup>[29]</sup>数据集(规模见表 1)。本文从原始发布与权威库中汇总得到药物集合、靶标集合、已知 DTI 标签矩阵以及同类关系信息: (1) 药物 SMILES 与二维结构信息来自 DrugBank (drugbank.com); (2) 靶标氨基酸序列来自 UniProt (uniprot.org); (3) 药物-药物与靶标-靶标相似度及其加权邻接矩阵按原始提供或基于特征计算得到, 用于同类通道的图增强。与 Luo 相比, Zheng 覆盖的药物与靶标更多, DTI/DDI/PPI 三类边更为密集, 分别约为 Luo 的 6、11、19 倍, 生物学上下文更丰富, 有利于表征学习与泛化评测。

**预处理与长度规范:** 对于靶标序列本文采用 ESM-2<sup>[10]</sup> 的官方分词器与编码器提取 CLS 表征; 对超长序列按模型上限进行截断与 padding, 实现中默认长度上限为 1000。

**相似度与图构建:** 同类通道(DDI/PPI)按相似度加权与稀疏化后参与异构图; 跨类通道严格仅使用当前训练折可见的 DTI 边, 测试折 DTI 不参与构图以避免信息泄露。

**划分与评测协议:** 为保证可比性, 本文采用了分层五折划分训练集和测试集的方式, 分别按药物与靶标的正样本数量分层后划分训练/测试索引以确保各折之间的正负样本数量尽量相同, 并在各折内独立进行图构建与样本生成。训练与测试阶段均采用与正样本数量 1:1 的负样本集, 用于进行鲁棒而一致的对比与消融实验。

表 1 实验数据集统计信息

Tab. 1 Statistics of experimental datasets

| 数据集   | 药物数  | 靶标数  | 药物-靶标相互作用数 | 药物-药物相互作用数 | 药物-药物结构相似度矩阵 | 靶标-靶标相互作用数 | 靶标-靶标序列相似度矩阵 |
|-------|------|------|------------|------------|--------------|------------|--------------|
| Luo   | 708  | 1512 | 1923       | 10036      | 708×708      | 7363       | 1512×1512    |
| Zheng | 1094 | 1556 | 11819      | 108206     | 1094×1094    | 138486     | 1556×1556    |

## 2.2 基线

为全面评估本文方法在 DTI 预测任务上的效果,本文选择了五个具有代表性的基线进行对比。所有方法均使用相同的数据划分方式、一致的评测协议,并在相同的正负样本比例设置下进行,以确保公平性。基线均采用其公开实现或论文推荐的默认超参数;若需适配本任务的数据格式,仅做最小化工程改动。

**DTINet<sup>[5]</sup>**: 该方法的核心是通过异构网络整合多元药物数据,并采用网络表示学习来自动提取节点的低维特征向量,这些向量能有效保留节点在网络中的拓扑特性;随后基于学习到的特征表示,通过向量空间投影模型预测潜在的药物-靶标相互作用关系。

**NeoDTI<sup>[6]</sup>**: 该方法是一种基于非线性端到端学习的药物-靶标相互作用预测方法,其核心思想是通过信息传递与聚合技术将卷积神经网络泛化应用于异构网络数据挖掘,自动学习能够保持网络拓扑结构的药物和靶标表征。该方法整合了来自异构网络的多元信息,利用图神经网络技术直接处理大规模图数据,实现了从原始网络数据到预测结果的端到端学习,在保持对超参数选择鲁棒性的同时,展现出卓越的预测性能。

**DTI-MGNN(Drug-Target Interaction predication via Multi-channel Graph Neural Networks)<sup>[30]</sup>**: 该方法采用多通道图神经网络架构,通过两个独立的图注意力网络分别学习拓扑图和特征图中节点间的差异化相互作用,同时利用共享权重的图卷积网络提取双图的共性信息。这种融合拓扑结构与语义特征的多通道设计,有效提升了药物-靶标相互作用的表征学习能力。

**AMGDTI(Adaptive Meta-Graph-based Drug-Target Interaction prediction)<sup>[31]</sup>**: 该方法采用了自适应元图学习方法,通过训练自动从异构网络中学习并聚合复杂的语义信息,无需依赖手工设计的元图或领域知识。该方法利用自适应元图的灵活性捕捉细粒度的网络拓扑关系,从而实现高效的异质信息整合和潜在的药物-靶标关系推断。

**NASNet-DTI(Drug-Target Interactions based on Node Adaptation and Similarity Networks)<sup>[32]</sup>**: 该方法采用基于节点自适应和相似性网络的异质图神经网络框架,通过图卷积网络分别提取药物和靶标的特征,并构建包含药物-药物、靶标-靶标及药物-靶标多重关系的异质网络。其核心创新在于引入节点自适应学习策略,为每个节点动态确定最优的邻域聚合深度,有效缓解了图神经网络中的过平滑问题,使每个节点都能学习到最具判别力的特征表示,从而显著提升了 DTI 预测的准确性。

## 2.3 评价指标与实验设置

本文使用曲线下面积(Area Under the Curve, AUC)和精确率-召回率曲线下面积(Area Under the Precision-Recall curve, AUPR)作为评价指标。各指标的最佳结果在表格中均以粗体标出。在对比实验中,本文在 Luo 和 Zheng 数据集上,以 1:1 的正负样本比例比较了 HDH-DTI 与所有基线方法的性能。此外,鉴于正负样本比例对 HDH-DTI 的性能有显著影响,为全面评估其表现,本文额外测试了该方法在正负样本比例为 1:1、1:5 及 1:10 三种不同情况下的结果。所有对比实验均基于五折交叉验证进行。在消融实验部分,本文逐一移除了本文方法中最可能影响性能的关键模块,并在 1:1 的正负样本比例下通过五折交叉验证评估它们的贡献。最后,本文还针对贡献最大的模块进行了参数敏感性分析,以探究其稳定性。

## 2.4 对比实验

为公平评估本文方法在 DTI 任务上的性能,本文选取了五种代表性基线进行对比。所有方法均采用相同的数据划分、评估协议等。基线方法均使用其公开实现或论文推荐的默认参数,如为适配数据格式仅做最小化工程改动。

表 2 展示了在 Luo 和 Zheng 数据集上采用 1:1 正负样本比例的五折交叉验证结果。可以看出,HDH-DTI 在所有实验中的 AUC 与 AUPR 均达到最优。

表 2 Luo 和 Zheng 数据集上的对比实验结果

Tab. 2 Comparative Experimental Results on the Luo and Zheng Datasets

| 数据集   | 方法         | AUC           | AUPR          |
|-------|------------|---------------|---------------|
| Luo   | DTINet     | 0.8636        | 0.8985        |
|       | NeoDTI     | 0.9503        | 0.8559        |
|       | DTI-MGNN   | 0.9666        | 0.9683        |
|       | AMGDTI     | 0.9770        | 0.9770        |
|       | NASNet-DTI | 0.9207        | 0.9232        |
|       | HDH-DTI    | <b>0.9783</b> | <b>0.9828</b> |
| Zheng | DTINet     | 0.8726        | 0.8912        |
|       | NeoDTI     | 0.9656        | 0.8605        |
|       | DTI-MGNN   | 0.9279        | 0.9213        |
|       | AMGDTI     | 0.9730        | 0.9710        |
|       | NASNet-DTI | 0.9195        | 0.9096        |
|       | HDH-DTI    | <b>0.9790</b> | <b>0.9818</b> |

具体而言,在 Luo 数据集上,本方法相较次优的 AMGDTI (AUC 0.9770 / AUPR 0.9770),两项指标分别提升了约 0.13 与 0.58 个百分点;而在 Zheng 数据集上提升更为显著,相对于 AMGDTI 的 AUC 0.9730 / AUPR 0.9710,分别提升约 0.60 与 1.08 个百分点。这表明在关系更稠密、信息更丰富的场景下,SE-HIG 对同类通道的加权机制与 DC-Encoder 的关系感知聚合能力得以更充分发挥。



值得注意的是, NeoDTI 在两个数据集上的 AUC 虽高, 但 AUPR 偏低, 反映出其在数据集的不平衡样本问题下的精确度保持能力受限。相比之下, 本文通过 TQ-CAHNS 在“药物簇×靶标簇”内实施自适应配额与难例加权采样, 有效增强了本文方法对困难负样本的辨识, 从而稳定提升了 AUPR 指标。

总体而言, 本文方法在规模与统计特性不同的两套数据集上均表现出稳健性, 且在大规模 Zheng 数据集上的 AUC 收益更为突出, 验证了“SE-HIG + DC-Encoder + TQ-CAHNS”组合架构对于泛化性与类别不平衡问题的良好适应性。

## 2.5 类别不平衡实验

类别不平衡实验结果(如表 3 所示)表明, 本文方法在 1:1 的正负样本比例下取得最优的 AUC 与 AUPR。当比例失衡时, AUC 指标仅在较小范围内波动, 从 0.9783 降至 0.9731/0.9741, 表明该方法基于 SE-HIG 与 DC-Encoder 学习的表征具有稳健的排序能力; 然而, AUPR 指标则随负样本增加而显著下降, 从 0.9828 降至 0.9446 与 0.9132, 累计降幅约 7.0 个百分点。这一现象符合预期: 负样本的过度增加会稀释正例并引入大量难以区分的负样本, 从而对精确率-召回率曲线造成冲击。

上述结果表明, SE-HIG 与 DC-Encoder 模块共同保障了本文方法在结构与语义层面的排名稳定性, 而 TQ-CAHNS 模块虽能部分缓解极端不平衡带来的影响, 却难以完全消除其对 AUPR 性能的损害。

表 3 Luo 数据集上的类别不平衡实验结果

Tab. 3 Class Imbalance Experimental Results on the Luo Dataset

| 正负样本比例 | AUC           | AUPR          |
|--------|---------------|---------------|
| 1:1    | <b>0.9783</b> | <b>0.9828</b> |
| 1:5    | 0.9731        | 0.9446        |
| 1:10   | 0.9741        | 0.9132        |

## 2.6 消融实验

为验证各关键模块的独立贡献与协同效应, 本文在与主实验相同的设置下进行了消融研究(结果如表 4 所示), 包括五折交叉验证、训练/测试集的 1:1 正负样本比例以及统一的优化器与训练轮数等。除目标模块被移除或修改外, 其余所有配置与数据划分均保持不变。

对于 SE-HIG 部分, 完整模块基于特征余弦相似度对 DDI/PPI 进行离线增强, 保留最大权重边, 并构建包含 DDI、PPI 及 DTI 关系的多元关系异构图。本文在该模块的消融设置中不引入相似度边, 仅使用原始结构边构建图。在 Luo 数据集上的消融结果显示, 移除该模块导致性能显著下降, AUC 从 0.9783 降至 0.9625, AUPR 从 0.9828 降至 0.9689, 表明基

于相似度的边增强有效提升了图结构的连通性与信噪比, 为后续表征学习奠定了基础。

对于 DC-Encoder 部分, 完整模块融合偏随机游走和 skip-gram 捕获的语义信息与关系感知 GraphSAGE 聚合的结构特征, 通过通道级拼接实现双路融合。消融设置包括仅使用 GraphSAGE 结构通道和仅使用 skip-gram 语义通道。实验结果表明, 仅使用 GraphSAGE(AUC: 0.9652, AUPR: 0.9695)或仅使用 skip-gram(AUC: 0.9750, AUPR: 0.9768)的效果均次于完整方法, 且语义通道贡献相对更突出, 说明拓扑上下文信息对排序性能至关重要, 双通道融合验证了语义与结构信息的互补性。

对于负采样策略部分, 完整策略基于 UMAP 与 HDBSCAN 进行药物与靶标聚类, 实施自适应配额和温度化难例加权的块内采样, 生成 1:1 平衡样本。消融设置包括无温和化配额、无难例加权和随机负采样三种变体。实验结果显示, 随机负采样导致性能急剧退化(AUC: 0.8804, AUPR: 0.8901), 凸显了簇感知与难例选择的关键作用; 移除自适应配额(AUC: 0.9747, AUPR: 0.9790)或难例加权(AUC: 0.9724, AUPR: 0.9772)均引起性能回升, 证明“跨簇均衡”与“块内难例挖掘”各自有效, 组合使用能达到最优。

表 4 Luo 数据集上的消融实验结果

Tab. 4 Ablation Study Results on the Luo Dataset

| 变体            | AUC           | AUPR          |
|---------------|---------------|---------------|
| w/o 相似度增强     | 0.9625        | 0.9689        |
| w/o skip-gram | 0.9652        | 0.9695        |
| w/o GraphSAGE | 0.9750        | 0.9768        |
| w/o TQ-CAHNS  | 0.8804        | 0.8901        |
| w/o 温和化配额     | 0.9747        | 0.9790        |
| w/o 难例加权      | 0.9724        | 0.9772        |
| 完整方法          | <b>0.9783</b> | <b>0.9828</b> |

从消融实验的结果来看, 三大模块各司其职且协同增效, SE-HIG 提升底层图数据质量, DC-Encoder 实现多视角表征互补融合, TQ-CAHNS 通过智能负采样保障方法在数据集的数据不平衡问题上的鲁棒性, 三者共同构成 HDH-DTI 达到最优性能的必要条件。

## 2.7 参数敏感性实验

为探究对性能影响最显著的 TQ-CAHNS 模块, 本文对其关键参数进行了敏感性分析, 最后的结果如表 5 所示。在 Luo 数据集上, 两个核心超参数均展现出单峰分布与宽稳区间的特性:

配额幂次  $\alpha$  的敏感性呈单峰特性:  $\alpha=0.65$  时最优(AUC 0.9783, AUPR 0.9828), 优于线性配额  $\alpha=1.0$  时的情况(AUC 0.9747, AUPR 0.9790), 说明自适应配额能抑制大簇垄断、提升跨簇覆盖。此外, 该参数在偏离最优时方法的性能有小

幅回落： $\alpha=0.50/0.80$  的 AUC 为 0.9677/0.9680(较最优降约 1.06/1.03 个百分点)，AUPR 为 0.9742/0.9743(较最优降约 0.86 个百分点)，分别对应过度均衡导致簇内代表性不足与趋近线性导致跨簇覆盖减弱的情况。

对于块内温度  $T$ ，在  $T=0.80$  时方法性能最优。当  $T$  降至 0.60 时，过度聚焦极难负例引入了噪声与不稳定性，导致性能轻微回落；当  $T$  升至 1.2 时，分布过度平缓削弱了难例区分度，致使性能显著下滑(AUC 降幅约为 0.5 个百分点)。

块内温度  $T$  的敏感性和  $\alpha$  一样也呈单峰特性： $T=0.8$  时方法性能最优(AUC 0.9783, AUPR 0.9828)。当  $T=0.6$  时，因过度聚焦极难负样本引入噪声与不稳定，AUC/AUPR 略降至 0.9745/0.9801；当  $T=1.2$  时，块内分布过度平滑削弱难例区分度，AUC/AUPR 降至 0.9730/0.9774，相对最优 AUC 下降约 0.0053，AUPR 下降约 0.0054。

整体上，AUPR 对超参变化的敏感度和 AUC 基本相似。参数在  $\alpha \in [0.5, 0.8]$  与  $T \in [0.6, 1.2]$  的宽泛区间内均能保持优良性能，强有力地验证了簇间均衡调配与块内难例聚焦这一分层设计理念的合理性与鲁棒性。

表 5 TQ-CAHNS 的参数敏感性分析

Tab. 5 Parameter Sensitivity Analysis of TQ-CAHNS

| 参数                | 参数值      | AUC           | AUPR          |
|-------------------|----------|---------------|---------------|
| 温和化配额<br>$\alpha$ | 0.50     | 0.9677        | 0.9742        |
|                   | 0.65(默认) | <b>0.9783</b> | <b>0.9828</b> |
|                   | 0.80     | 0.9680        | 0.9743        |
|                   | 1.00(线性) | 0.9747        | 0.9790        |
| 难例温度<br>$T$       | 0.60     | 0.9745        | 0.9801        |
|                   | 0.80(默认) | <b>0.9783</b> | <b>0.9828</b> |
|                   | 1.20     | 0.9730        | 0.9774        |

### 3 结语

本文针对 DTI 预测任务提出了 HDH-DTI 方法，该方法在结构层面引入相似度边以缓解拓扑稀疏问题，为后续表征学习提供更优的结构基础；在表征层面融合高阶拓扑信息与语义上下文，增强节点表征的判别能力；在样本层面显式缓解类别不平衡与未标注负例带来的噪声影响，提升了方法在复杂分布下的训练稳定性。整体而言，本文构建了一个结构、表征与样本协同优化的 DTI 预测方法，为复杂生物关联预测任务的研究提供了系统性参考。在两个公开数据集上的实验结果表明，HDH-DTI 在 AUC 与 AUPR 指标上均优于现有基线方法。

尽管 HDH-DTI 在 DTI 预测方面表现出色，但本研究仍存在若干有待改进之处。首先，图构建依赖于预计算的离线相似度，缺乏端到端的可学习边权机制，限制了方法对动态噪声分布的适应能力。其次，“未标注即负例”的基本假设

可能引入潜在正例噪声，且基于平衡采样的评估协议与真实场景的全库筛选存在差距。此外，负采样策略中的关键超参数及聚类结果对性能具有显著影响，虽然增强了可解释性，但也带来了一些调优成本与数据集依赖性。再者，方法的集成度仍有提升空间，部分扩展模块尚未完全融入主干网络的端到端训练流程。最后，该方法在跨数据集、零样本及分布外场景下的泛化能力仍需更系统性的验证。

针对上述问题，未来的研究工作将重点围绕以下几个方面展开：开发生态图学习方法，实现端到端的可学习图结构构建，并引入不确定性建模以提升对噪声数据的控制；在保持 DTI 预测核心任务的同时，引入更丰富的生物医学上下文信息，并发展可解释性分析方法以增强模型的生物学洞察力，多源生物医学数据的有效融合是实现这一目标的重要基础<sup>[33]</sup>；建立系统化的跨领域评估体系，构建涵盖零样本及分布外泛化的标准化评测基准；同时优化训练与部署效率，研究先进的采样策略与模型压缩技术，为实际应用提供技术支持。

### 参考文献

- [1] Chen Ruolan, Liu Xiangrong, Jin Shuting, et al. Machine learning for drug-target interaction prediction[J]. *Molecules*, 2018, 23(9): 2208.
- [2] Yamanishi Y, Araki M, Gutteridge A, et al. Prediction of drug-target interaction networks from the integration of chemical and genomic spaces[J]. *Bioinformatics*, 2008, 24(13): i232-i240.
- [3] Xia Zheng, Wu Lingyun, Zhou Xiaobo, et al. Semi-supervised drug-protein interaction prediction from heterogeneous biological spaces[J]. *BMC Systems Biology*, 2010, 4(Suppl 2): S6.
- [4] Liu Yong, Wu Min, Miao Chunyan, et al. Neighborhood regularized logistic matrix factorization for drug-target interaction prediction[J]. *PLOS Computational Biology*, 2016, 12(2): e1004760.
- [5] Luo Yunan, Zhao Xinbin, Zhou Jinglin, et al. A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information[J]. *Nature Communications*, 2017, 8(1): 573.
- [6] Wan Fangping, Hong Lixiang, Xiao An, et al. NeoDTI: neural integration of neighbor information from a heterogeneous network for discovering new drug-target interactions[J]. *Bioinformatics*, 2019, 35(1): 104-111.
- [7] Öztürk H, Özgür A, Ozkirimli E. DeepDTA: deep drug-target binding affinity prediction[J]. *Bioinformatics*, 2018, 34(17): i821-i829.
- [8] Tsubaki M, Tomii K, Sese J. Compound-protein interaction prediction with end-to-end learning of neural networks for graphs and sequences[J]. *Bioinformatics*, 2019, 35(2): 309-318.
- [9] Chithrananda S, Grand G, Ramsundar B. ChemBERTa: large-scale self-supervised pretraining for molecular property prediction[EB/OL]. [2026-03-17]. DOI:10.48550/arXiv.2010.09885.
- [10] Lin Zeming, Akin H, Rao Roshan, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. *Science*, 2023, 379(6637): 1123-1130.
- [11] Grover A, Leskovec J. Node2vec: scalable feature learning for networks[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 855-864.
- [12] Hamilton W L, Ying R, Leskovec J. Inductive representation learning on large graphs[C]//Proceedings of the 31st Annual Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 1025-1035.

- [13] Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(2): 318-327.
- [14] McInnes L, Healy J, Saul N, et al. UMAP: uniform manifold approximation and projection[J]. Journal of Open Source Software, 2018, 3(29): 861.
- [15] Campello R J G B, Moulavi D, Sander J. Density-based clustering based on hierarchical density estimates[C]//Proceedings of the 17th Pacific-Asia Conference on Knowledge Discovery and Data Mining. Cham: Springer, 2013: 160-172.
- [16] Hinton G E, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB/OL]. [2026-03-17]. DOI:10.48550/arXiv.1503.02531.
- [17] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010.
- [18] Chen Lifan, Tan Xiaoqin, Wang Dingyan, et al. TransformerCPI: improving compound-protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments[J]. Bioinformatics, 2020, 36(16): 4406-4414.
- [19] Dwivedi V P, Bresson X. A generalization of transformer networks to graphs[C]//Proceedings of the 5th International Workshop on Deep Learning on Graphs: Methods and Applications (DLG-AAAI 2021). Virtual: AAAI Press, 2021, doi: 10.48550/arXiv.2012.09699.
- [20] Gao Mengmeng, Zhang Daokun, Chen Yi, et al. GraphormerDTI: a graph transformer-based approach for drug-target interaction prediction[J]. Computers in Biology and Medicine, 2024, 173: 108339.
- [21] Goldberg Y, Levy O. Word2vec explained: deriving Mikolov et al.'s negative-sampling word-embedding method[EB/OL]. [2026-03-17]. DOI:10.48550/arXiv.1402.3722.
- [22] Ba J L, Kiros J R, Hinton G E. Layer normalization[EB/OL]. [2026-03-17]. DOI:10.48550/arXiv.1607.06450.
- [23] Mikolov T, Sutskever I, Chen Kai, et al. Distributed representations of words and phrases and their compositionality[C]//Proceedings of the 27th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2013: 3111-3119.
- [24] Chen Ting, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//Proceedings of the 37th International Conference on Machine Learning. Vienna: PMLR, 2020: 1597-1607.
- [25] Tang Jian, Qu Meng, Wang Mingzhe, et al. LINE: large-scale information network embedding[C]//Proceedings of the 24th International Conference on World Wide Web. New York: ACM, 2015: 1067-1077.
- [26] Kingma D P, Ba J. Adam: a method for stochastic optimization[EB/OL]. [2026-03-17]. DOI:10.48550/arXiv.1412.6980.
- [27] Loshchilov I, Hutter F. SGDR: stochastic gradient descent with warm restarts[C]//Proceedings of the 5th International Conference on Learning Representations (ICLR 2017). Toulon, France: OpenReview.net, 2017, doi: 10.48550/arXiv.1608.03983.
- [28] Sharifabad M M, Sheikhpour R, Gharaghani S. BRNS + SSFSM-DTI: a hybrid method for drug-target interaction prediction based on balanced reliable negative samples and semi-supervised feature selection[J]. Chemometrics and Intelligent Laboratory Systems, 2022, 220: 104462.
- [29] Zheng Yi, Peng Hui, Zhang Xiaocai, et al. Predicting drug targets from heterogeneous spaces using anchor graph hashing and ensemble learning[C]//Proceedings of the 2018 International Joint Conference on Neural Networks. Piscataway: IEEE, 2018: 1-7.
- [30] Li Yang, Qiao Guanyu, Wang Keqi, et al. Drug-target interaction prediction via multi-channel graph neural networks[J]. Briefings in Bioinformatics, 2022, 23(1): bbab346.
- [31] Su Yansen, Hu Zhiyang, Wang Fei, et al. AMGDTI: drug-target interaction prediction based on adaptive meta-graph learning in heterogeneous network[J]. Briefings in Bioinformatics, 2024, 25(1): bbad474.
- [32] Zhong Ningyu, Du Zhihua. NASNet-DTI: accurate drug-target interaction prediction using heterogeneous graphs and node adaptation[J]. Briefings in Bioinformatics, 2025, 26(4): bbaf342.
- [33] 刘晓光, 李梅. 基于深度学习的药物-靶标相互作用预测研究综述[J]. 智能系统学报, 2024, 19(3): 494-524. (Liu Xiaoguang, Li Mei. A survey of deep learning-based drug-target interaction prediction [J]. CAAI Transactions on Intelligent Systems, 2024, 19(3): 494-524.)

★【必须确认并说明情况】与论文、专利等的相关性说明:

温馨提示: 我刊投稿时已经明确要求稿件内容需是原创、首发, 以任何形式、语言发表、公开过的内容不宜再次投稿, 如果本稿与作者本人的学位论文、专利等密切相关, 请与责编先联系说明情况, 如果作者未明确说明而在后续处理查重中发现这类情况, 稿件可能无法再受理, 还请理解。

请回复说明是否存在以下情况: 本文稿件主要技术内容是否计划或已经申请相关专利, 已申请专利的是否已经公开或计划何时公开; 是否为已经完成答辩论文中的章节(何时完成答辩)或是即将作为拟提交学位论文的章节(计划提交的时间)。注意析出小论文与相关的专利、学位论文等在署名、单位等主要责任者应该相符。(比如学位论文单位和本文单位应该一致, 前两个作者应该是学位论文的老师或学生)

作者回复: 不计划申请相关专利, 不是已经完成答辩论文中的章节, 不作为即将拟提交学位论文的章节。

★【必须填写】依次写明所有作者在本文中的工作量:

第一作者: 魏传如, 负责提出论文方法、实现代码、训练与测试提出的模型、撰写论文。

第二作者: 刘炯鑫, 负责整理相关数据集。

第三作者: 乐佳檬, 负责制作论文中的图表

第四作者: 刘明铭, 负责指导方法的实现与论文的写作

第五作者: 罗永楠, 负责训练与测试基准模型

第六作者: 秦红, 负责训练与测试基准模型

第七作者: 于广博, 负责训练与测试基准模型

## ★【补充英文作者和基金信息】：

为了更好地开展国际交流，本刊计划刊登作者信息和基金项目信息的英文译文，请在参考文献的后面加上该信息（格式如样例）。---原有的中文作者信息不用删除。**CCF** 会员信息英文作者简介中不用写出，另外，学历请按规范填写。

This work is partially supported by the Natural Science Foundation of Tianjin (22JCYBJC01020).

WEI Chuanru, born in 2002, M. S. candidate. His research interests include machine learning, biological link prediction.

LIU Jiongxin, born in 2002, M. S. candidate. His research interests include machine learning, biological link prediction.

LE Jiameng, born in 2001, M. S. candidate. Her research interests include machine learning, biological link prediction.

LIU Mingming, born in 1979, Ph. D., associate professor. Her research interests include data mining, machine learning.

LUO Yongnan, born in 2003, M. S. candidate. His research interests include machine learning, biological link prediction.

QIN Hong, born in 2002, M. S. candidate. Her research interests include machine learning, biological link prediction.

YU Guangbo, born in 2003, M. S. candidate. His research interests include machine learning, biological link prediction.

## ★【基金项目介绍】：

| 第一项基金项目（多个基金依次在后面列出） |                               |
|----------------------|-------------------------------|
| 基金项目种类               | 天津市自然科学基金                     |
| 基金项目编号               | 22JCYBJC01020                 |
| 基金项目名称               | 基于图神经网络的药物-靶标相互作用预测方法研究       |
| 基金项目主持人              | 刘明铭                           |
| 基金项目起止时间             | 2022.10 至 2025.09（已结题，但还在存续期） |
| 基金项目主要研究内容           | 研究基于图神经网络预测药物-靶标相互作用          |

|                |     |                   |                |
|----------------|-----|-------------------|----------------|
|                |     | 的方法               |                |
| 本文内容与项目研究的关系   |     | 本文研究内容与基金项目研究内容一致 |                |
| 各作者在项目中承担的工作内容 |     |                   |                |
| 文章中作者署名排序      | 姓名  | 在项目承担人中的排名        | 在项目承担的工作内容     |
| 第 1 作者         | 魏传如 | 1                 | 主要负责相关算法的研究和实现 |
| 第 2 作者         | 刘炯鑫 | 2                 | 主要负责相关算法的研究和实现 |
| 第 3 作者         | 乐佳檬 | 3                 | 主要负责相关算法的研究和实现 |
| 第 4 作者         | 刘明铭 | 4                 | 主要负责相关算法的研究和实现 |
| 第 5 作者         | 罗永楠 | 5                 | 主要负责相关算法的研究和实现 |
| 第 6 作者         | 秦红  | 6                 | 主要负责相关算法的研究和实现 |
| 第 7 作者         | 于广博 | 7                 | 主要负责相关算法的研究和实现 |

## ★矩阵、向量变量符号说明：

矩阵变量如下： $\mathbf{X}_d$ ,  $\mathbf{X}_p$ ,  $\mathbf{X}_d^{\text{norm}}$ ,  $\mathbf{X}_p^{\text{norm}}$ ,  $\mathbf{S}_d$ ,  $\mathbf{S}_p$ ,  $\mathbf{A}^d$ ,  $\mathbf{A}^p$ ,  $\mathbf{h}$ ,  $\bar{\mathbf{h}}$ ,  $\tilde{\mathbf{h}}$ ,  $\mathbf{W}_{\text{neigh}}$ ,  $\mathbf{W}_{\text{self}}$ ,  $\mathbf{g}$ ,  $\mathbf{z}$ ,  $\mathbf{e}$ ,  $\hat{\mathbf{e}}$ ,  $\hat{\mathbf{g}}$ ,  $\mathbf{W}_e$ ,  $\mathbf{b}_e$ ,  $\mathbf{W}_g$ ,  $\mathbf{b}_g$ ,  $\mathbf{x}$ ,  $\mathbf{Y}$ ,  $\mathbf{x}_d^{\text{base}}$ ,  $\mathbf{x}_p^{\text{base}}$ ,  $\mathbf{z}_d$ ,  $\mathbf{z}_p$ ,  $\boldsymbol{\omega}_d$ ,  $\boldsymbol{\omega}_p$ ,  $\mathbf{x}_d^{\text{proj}}$ ,  $\mathbf{x}_p^{\text{proj}}$ ,  $\mathbf{W}_\xi$ ,  $\mathbf{b}_\xi$ ,  $\boldsymbol{\omega}$ ,  $\tilde{\mathbf{x}}_d^{\text{proj}}$ ,  $\tilde{\mathbf{x}}_p^{\text{proj}}$ ,  $\mathbf{W}_d$ ,  $\mathbf{W}_p$ 。

向量变量如下： $\boldsymbol{\psi}_1$ ,  $\boldsymbol{\psi}_2$ ,  $\boldsymbol{\psi}^{\text{orig}}$ ,  $\boldsymbol{\psi}_{\text{pair}}$ 。

正体上下标及其含义：

d: 药物的 (drug)

p: 靶标的 (protein)

norm: 归一化后的 (normalized)

T: 矩阵转置 (transpose)

orig: 原始值的 (original)

sim: 相似度的 (similarity)

weight: 权重的 (weight)

DDI: 药物-药物相互作用的 (drug-drug interaction)

PPI: 蛋白质-蛋白质相互作用的 (protein-protein interaction)

DTI: 药物-靶标相互作用的 (drug-target interaction)

neigh: 邻居节点的 (neighbor)

self: 自身节点的 (self)

sg: skip-gram 主损失的

e: 词嵌入的 (embedding)

g: 图嵌入的 (graph embedding)

ntxent: NT-Xent 对比损失的

ns: 邻居对比损失的

con: 对比损失权重相关的 (contrastive)

sage: GraphSAGE 相关的

neg: 负样本的 (negative)

cand: 候选样本的 (candidate)

base: 基础特征的 (base features)

proj: 投影后的特征的 (projected)

pair: 对偶表示的 (pair representation)

focal: Focal Loss 相关的

其他是普通变量 (不用罗列)。

“ChemBERTa”是一个独立的、专有的模型名称，指代“将 RoBERTa 架构应用于化学分子 SMILES 字符串表示学习的预训练模型”。本文遵循学术惯例，直接使用了其原名并引用原始文献。

#### ★关于图片的说明:

当前文档中的图片改成了 png 图片以防止出现跨平台解析导致的清晰度下降的问题，方便打印校对，矢量图在邮件的图片包中，原始文件是 pdf 矢量图，同时提供了基于 CorelDRAW X8 导出的 cdr、emf、png、svg 文件，矢量图导入 CorelDRAW X8 中后文字可编辑。

#### ★关于缩略语的说明:

本文中提及的“ChemBERTa”模型，其名称来源于“Chemical RoBERTa”的组合缩写。需要说明的是，根据对该模型原始文献 (Chithrananda et al., 2020) 的查证，该模型在提出时直接被命名为“ChemBERTa”，原文中并未给出逐一对应每个字母的传统意义上的“全称”。因此，在学术语境下，